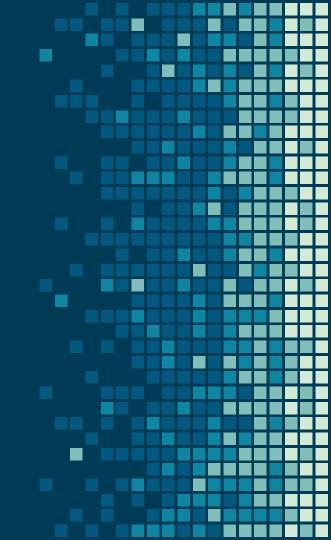
# MACHINE LEARNING

Uma introdução prática





# HELLO WORLD!

#### **Autores**

@colombelli

fcolombelli@inf.ufrgs.br

@jpelax

jprodrigues@inf.ufrgs.br

#### **Monitores**

@birromer

bhflores@inf.ufrgs.br

@phpgit2

pedro.fiorentin@inf.ufrgs.br

# 2. Enfoque do curso

Redes neurais artificiais na prática

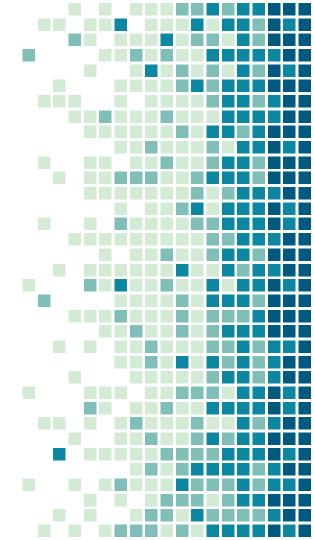


#### TECNOLOGIAS E FERRAMENTAS

- Python + Google Colab
- Keras
- TensorFlow
- PyTorch
- Scikit-Learning

# 3. Motivação

Por que estudar machine learning?



## Para quê?

Robótica



Governo



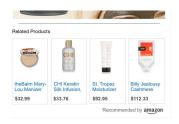
Transporte



Negócios



Varejo



Saúde





#### Data doesn't lie

 "In the past year, the number of PhD graduates on LinkedIn who say they have AI expertise has risen by 66%" - Nature.com

"Machine learning engineer is the best job of 2019 due to growing demand and high salaries" - Indeed.com

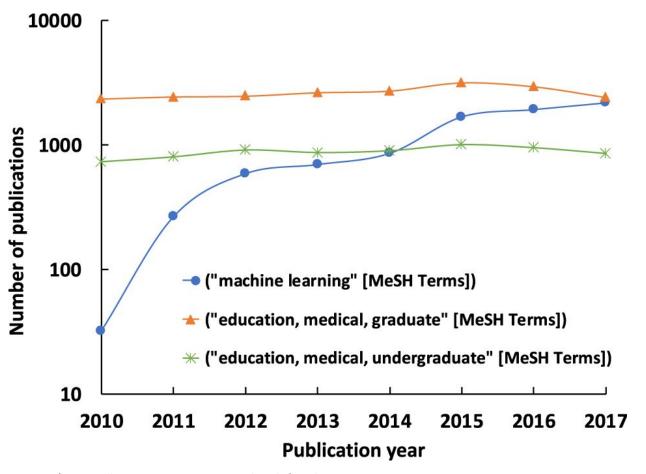
 "Global machine learning market is expected to grow from \$1.4B in 2017 to \$8.8B by 2022" -ResearchAndMarkets.com

#### Indeed's best jobs of 2019

Rank	Job title	% growth in # of postings, 2015–2018	Average base salary	# of postings per 1million total tobs, 2018
1	Machine Learning Engineer	344%	\$146,085	179
2	Insurance Broker	242%	\$86,498	32
3	Full-stack Developer	206%	\$114,316	828
4	Insurance Advisor	190%	\$81,479	45
5	Litigation Attorney	168%	\$101,289	92
6	Litigation Associate	165%	\$98,982	53
7	Dental Hygienist	157%	\$78,110	878
8	Associate Attorney	149%	\$75,515	281
9	Realtor	138%	\$96,820	221
10	Salesforce Developer	129%	\$112,031	170

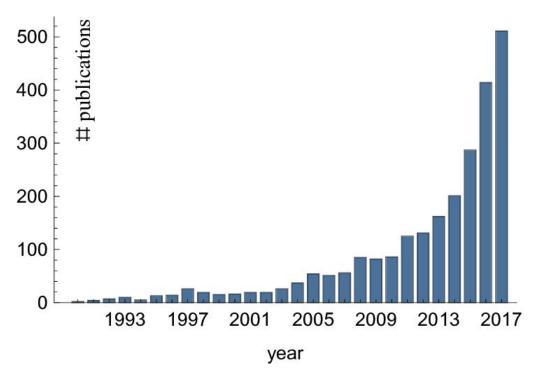
Job title's

Fonte: http://blog.indeed.com/2019/03/14/best-jobs-2019/



Fonte: https://www.nature.com/articles/s41746-018-0061-1

Number of publications per year from a web of science search for articles with topics of machine learning and either chemistry or materials.



Fonte:https://www.researchgate.net/figure/Number-of-publications-per-year-from-a-web-of-science-search-for-articles-with-topics-of\_fig1\_326028833

Conceitos envolvidos Situando-se nesse universo de informações

## Artificial Intelligence vs Machine Learning

- Conceito mais amplo
- Uso de computadores para imitar funções cognitivas de seres humanos
- Algoritmos que funcionam de maneira inteligente

- Subárea de IA
- Foca na habilidade possuída por máquinas de receber um conjunto de dados e aprenderem por si próprias

## Data Science vs Data Mining

- Uma área
- Multidisciplinar
- Análise social, construção de modelos preditivos, descobrimento de fatos desconhecidos, etc
- Foco na ciência

- Um conjunto de técnicas
- Faz parte de Data Science
- Achar padrões e tendências
- Foco no processo / algoritmos

## Supervised vs Unsupervised Learning

Supervised learning trabalha em cima de dados rotulados

- Classificação: quando a variável de saída é uma categoria
- Regressão: quando a variável de saída é um número real
- Algoritmos: SVM, Random Forest, Linear Regression, Redes neurais

Unsupervised learning só tem os dados "crus"

- Clustering: agrupamentos de dados (k-means)
- Association: quando se quer descobrir regras que governam os dados como "pessoas que compram X também tendem a comprar Y" (Apriori algorithm)

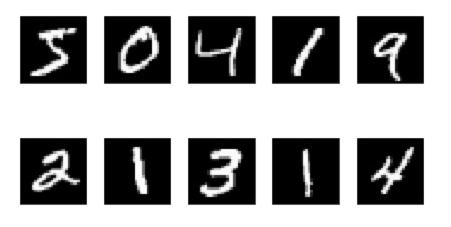
## E quanto a redes neurais vs deep learning?

Guardem no buffer...

5.
Redes Neurais
Artificiais, Teoria

Primeiro vamos entender teoricamente como uma ANN funciona.

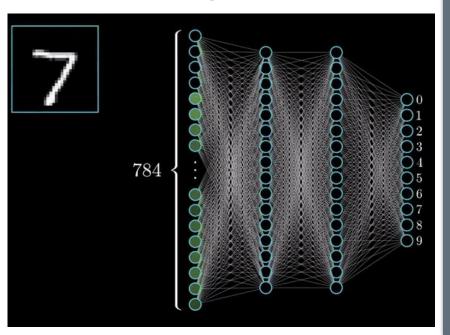




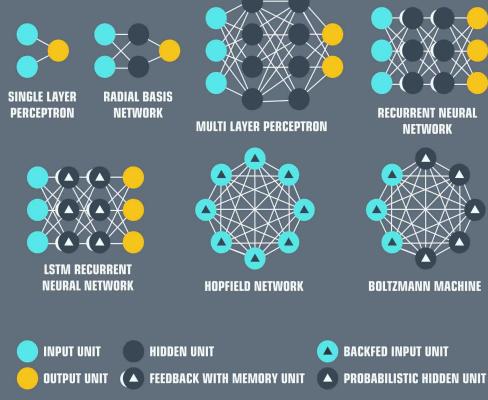
- Como seu cérebro consegue classificar cada dígito?
- Como você escreveria um algoritmo para identificar cada imagem como um dígito específico?
- Tarefas complexas!

## Há diversas variações de redes neurais

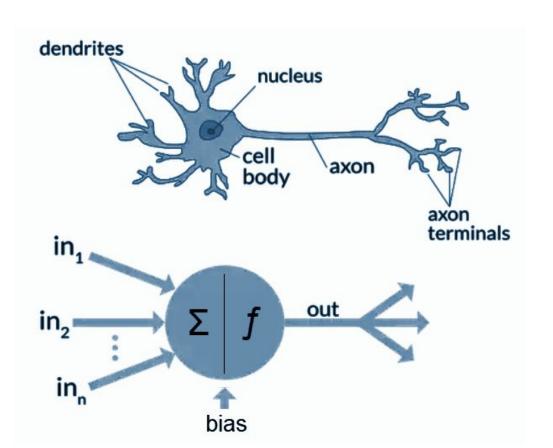
Neste curso focaremos em Multilayer Perceptron (obrigado 3b1b)

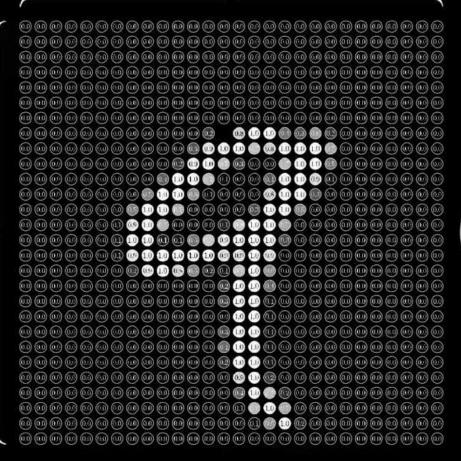


## NEURAL NETWORK ARCHITECTURE TYPES



## Inspiração Biológica



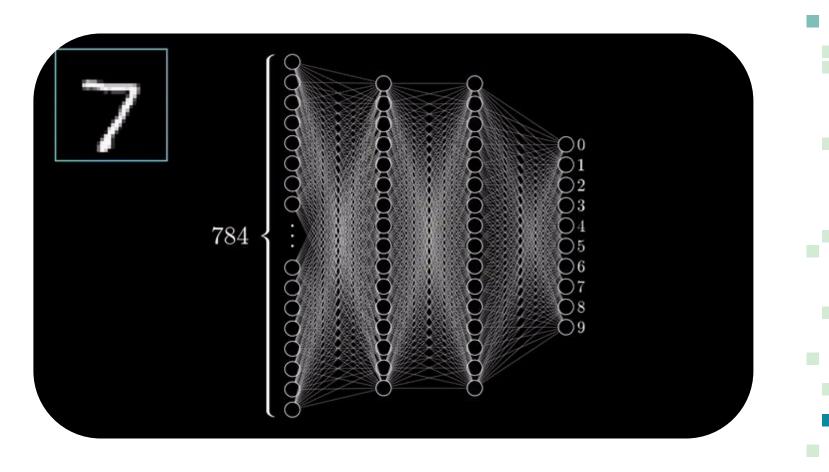


28

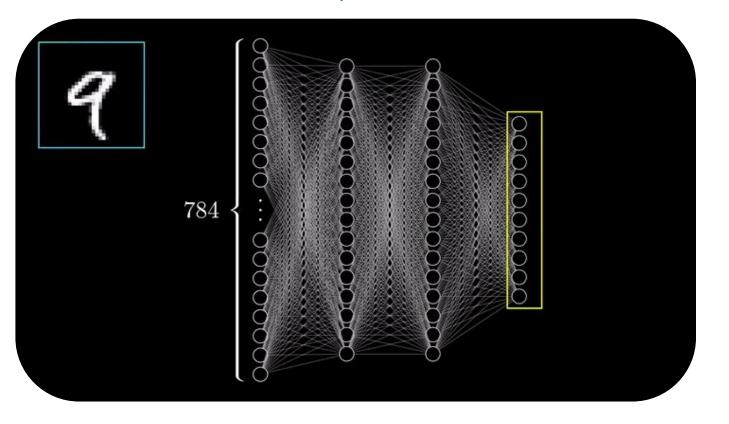
 $28 \times 28 = 784$ 

0.58

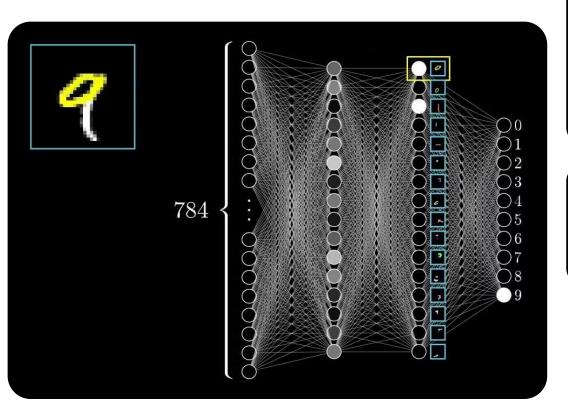
"Activation"

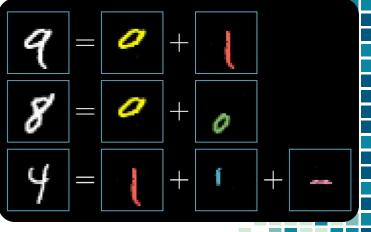


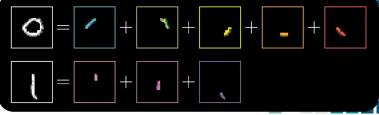
## A camada de Output



## Hidden Layers





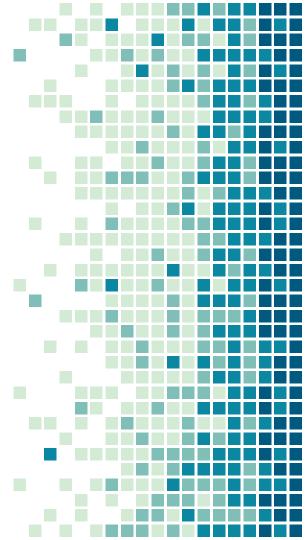


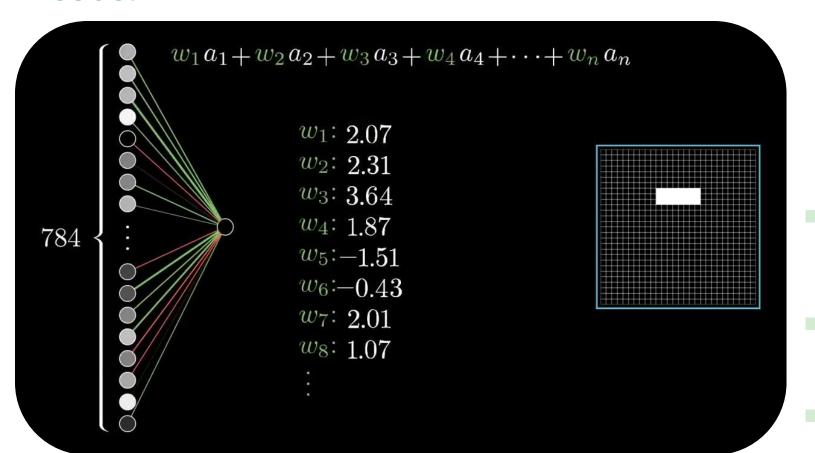
#### HIDDEN LAYERS

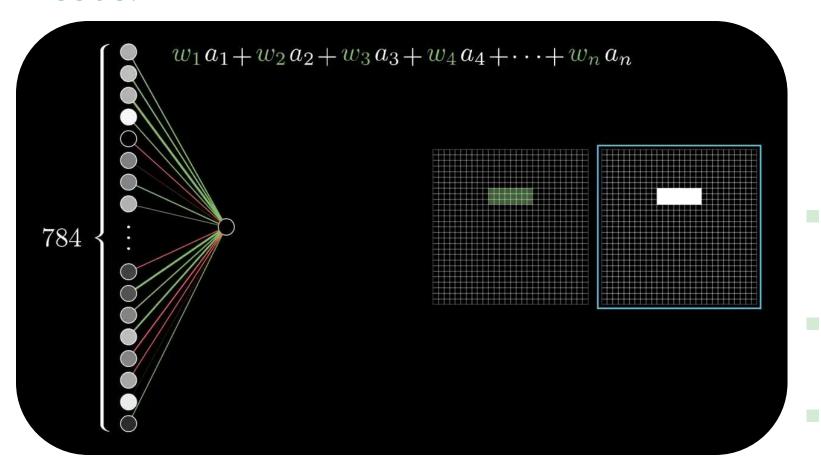
- Quebrar tarefas complexas
- Melhorar performance
- Muitos exemplos podem explorar essa característica

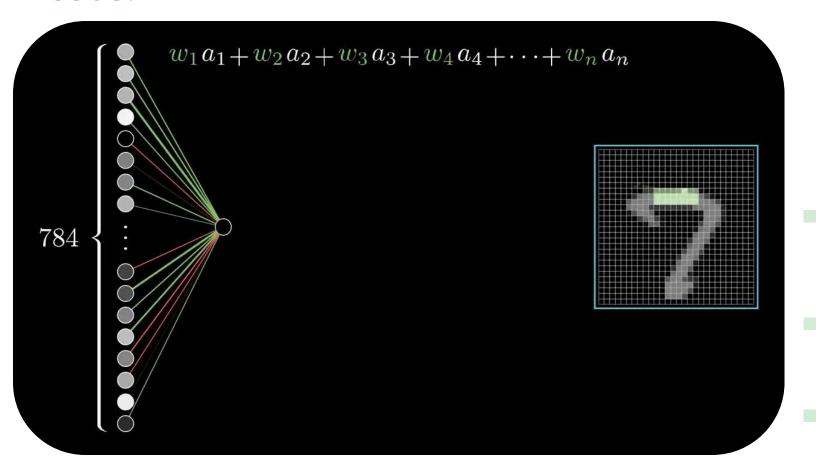
Reconhecimento facial, reconhecimento de fala, etc

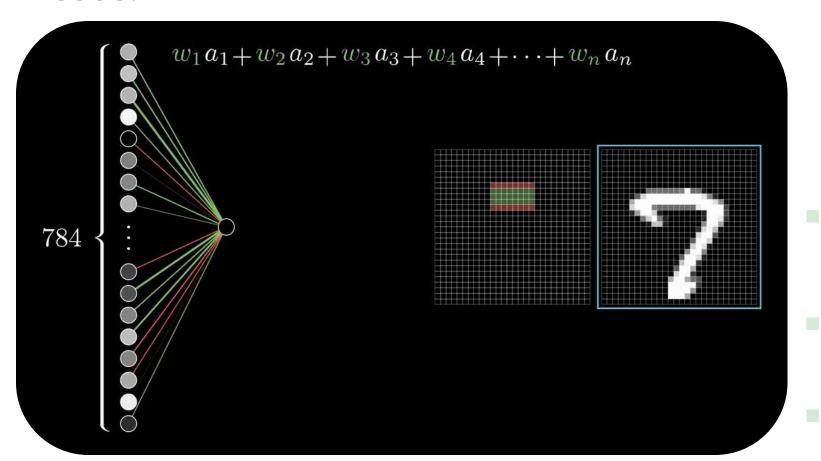
COMO FAZEMOS AS ATIVAÇÕES DE UMA CAMADA AFETAR AS OUTRAS?

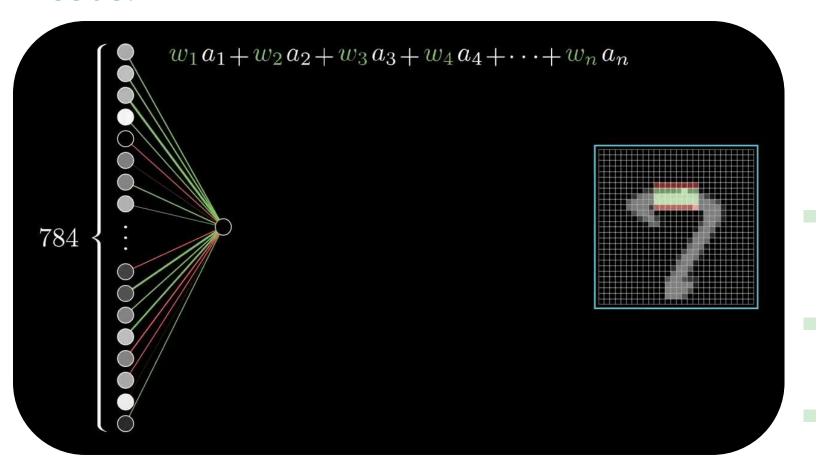




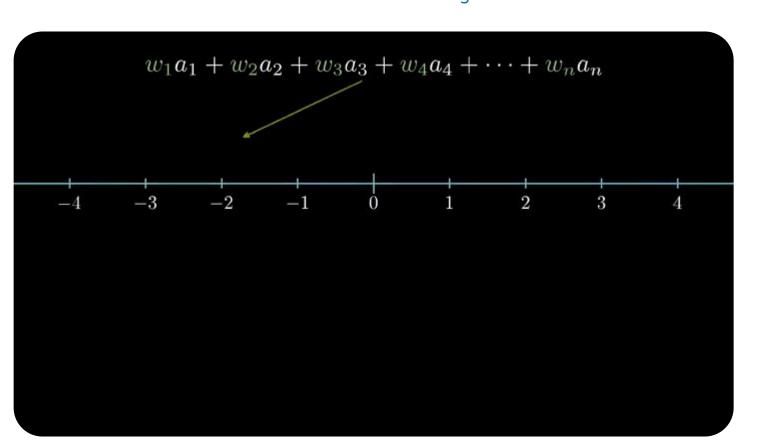




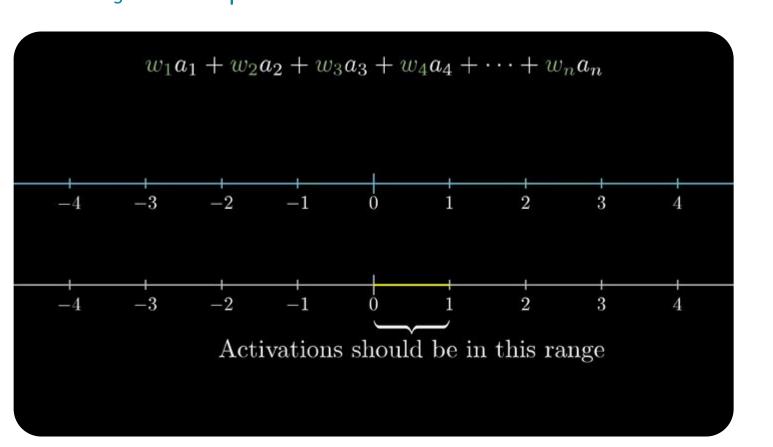




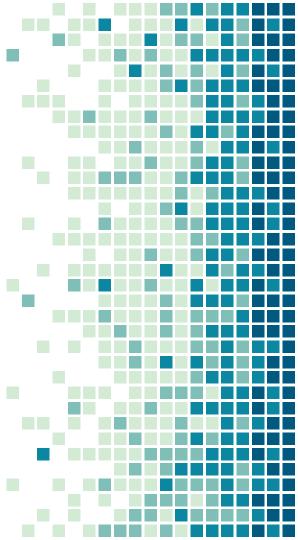
## Problema: valor de ativação muito alto



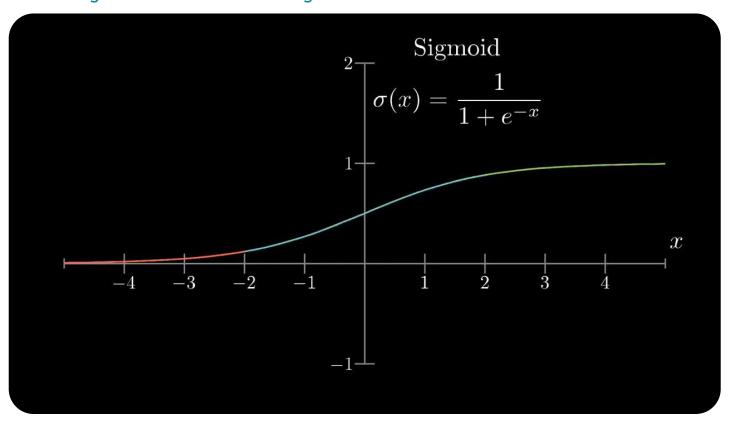
#### Solução: espremer valores num intervalo



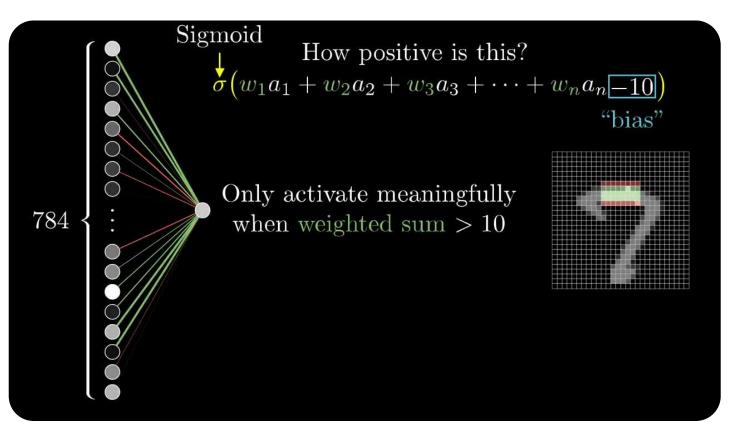
COMO FAZER COM QUE AS ATIVAÇOES **ESTEJAM** DELIMITADAS EM UM INTERVALO ESPECÍFICO?



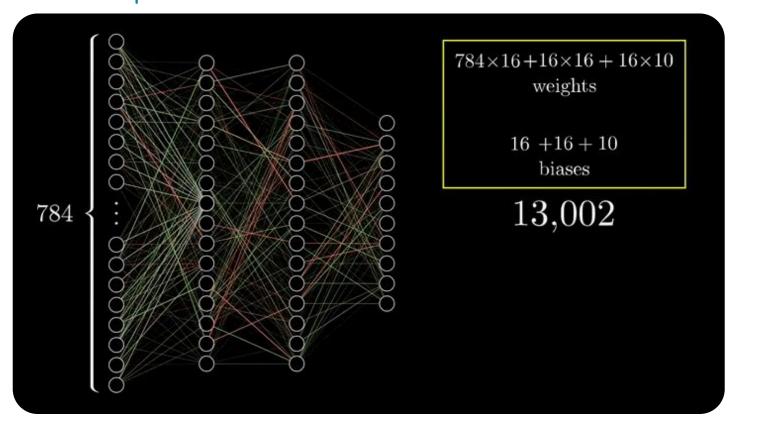
## Função de Ativação



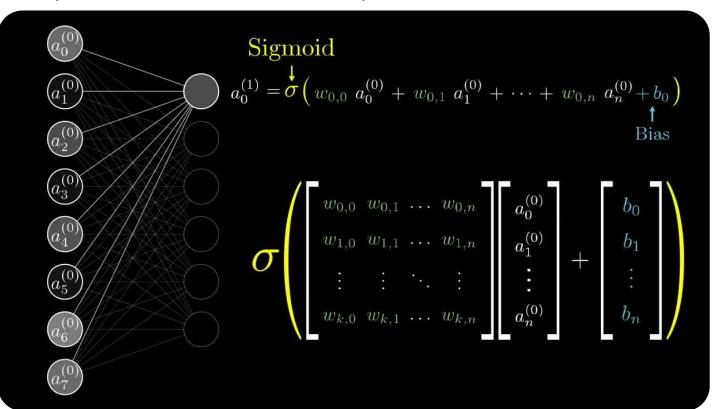
#### Bias



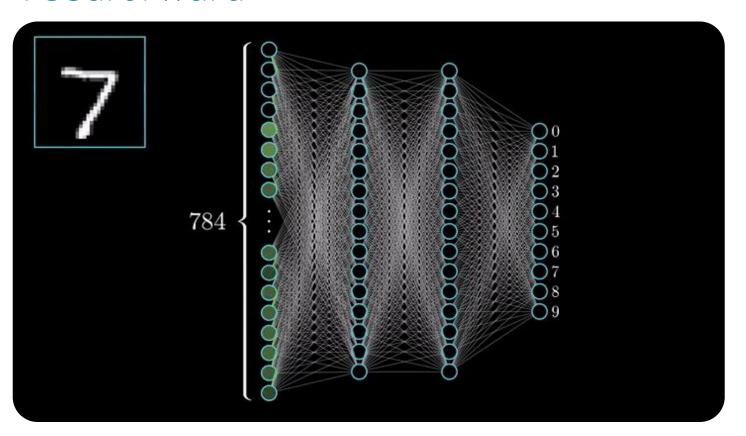
### E isso para todos os neurônios...



#### Representação compacta formal



#### Feedforward

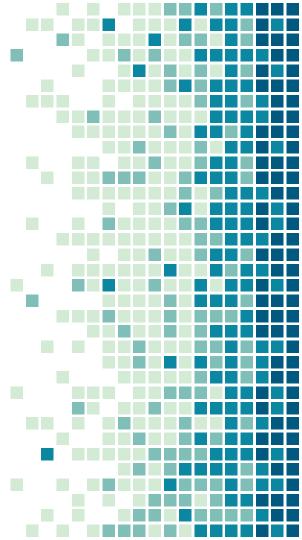


#### O PROCESSO DE APRENDIZAGEM

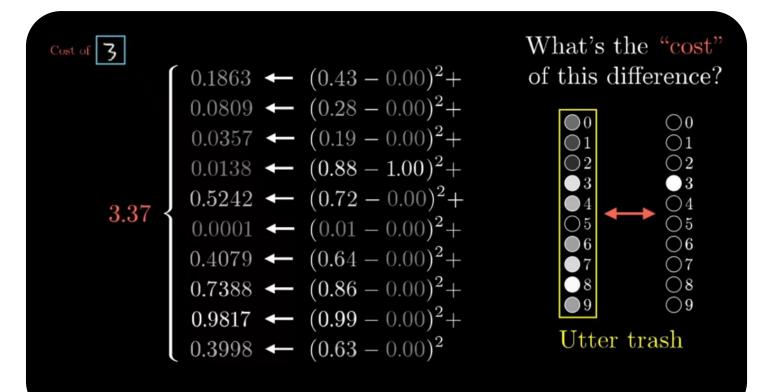


- 1. Iniciamos a rede com pesos e bias aleatórios
- 2. Alimentamos com uma amostra
- 3. Calculamos o erro do output
- 4. Atualizamos os pesos baseado nesse erro
- 5. Retornamos ao passo 2.

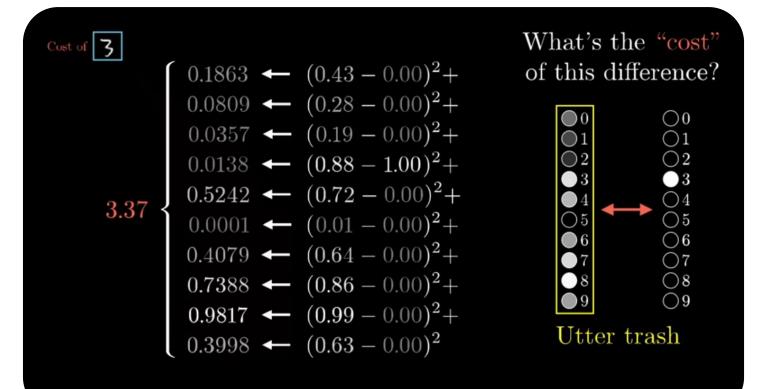
COMO CALCULAR O ERRO ENTRE A SAIDA DA REDE NEURAL E A SAIDA IDEAL?



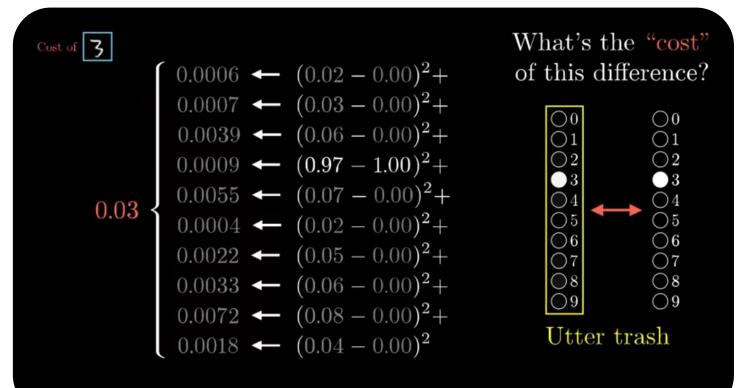
#### **Cost Functions!**



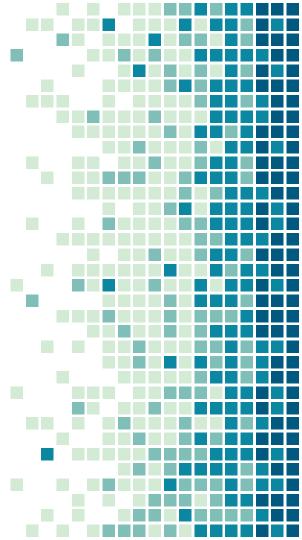
#### Alto quando ela ainda não foi treinada

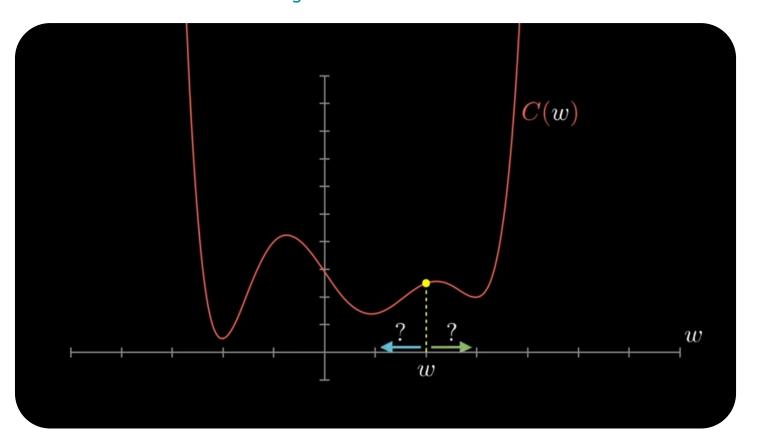


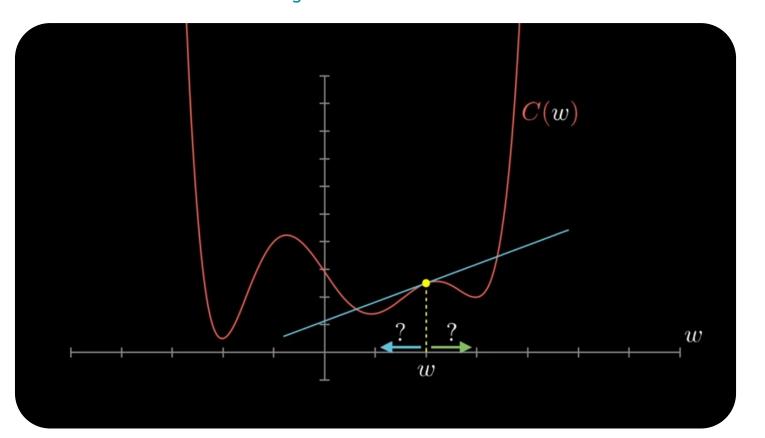
#### Baixo quando ela se aproxima do correto

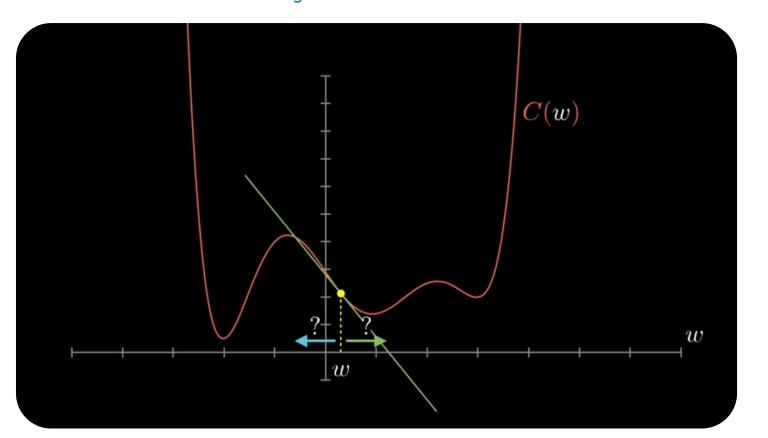


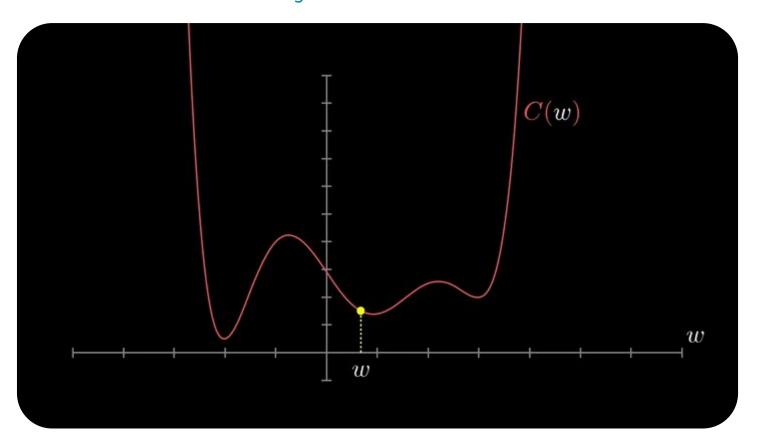
CALCULADO O CUSTO, COMO ATUALIZAMOS OS VALORES DOS PESOS?



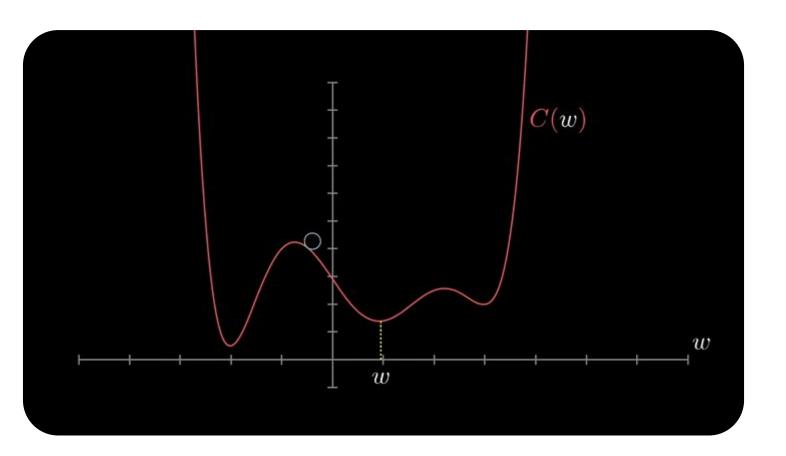




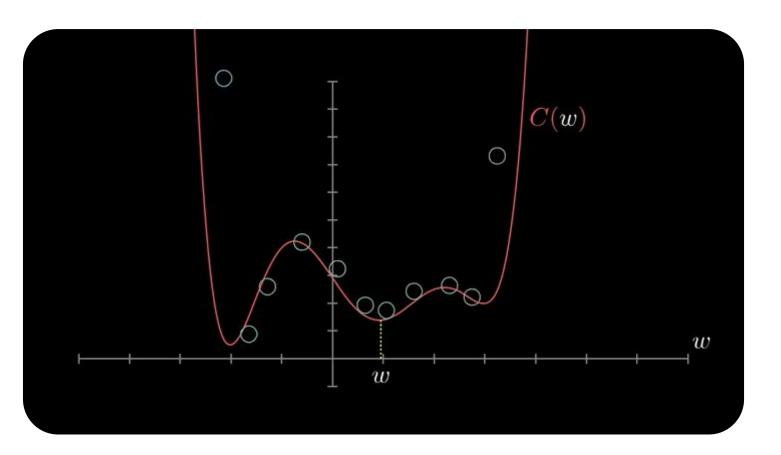




#### "Bola descendo um morro"



#### Vários mínimos locais

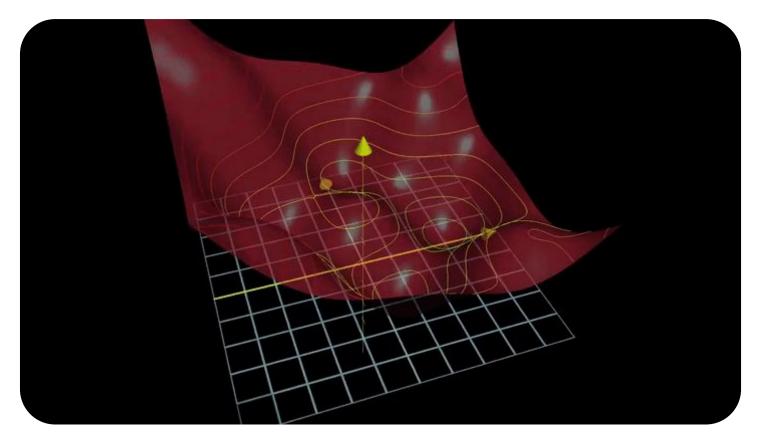


Você pode acabar em diversos vales distintos dependendo do input randômico inicial.

Não há nenhuma garantia de que o mínimo local encontrado seja o menor valor possível para a função de custo.



### O algoritmo para minimizar a função

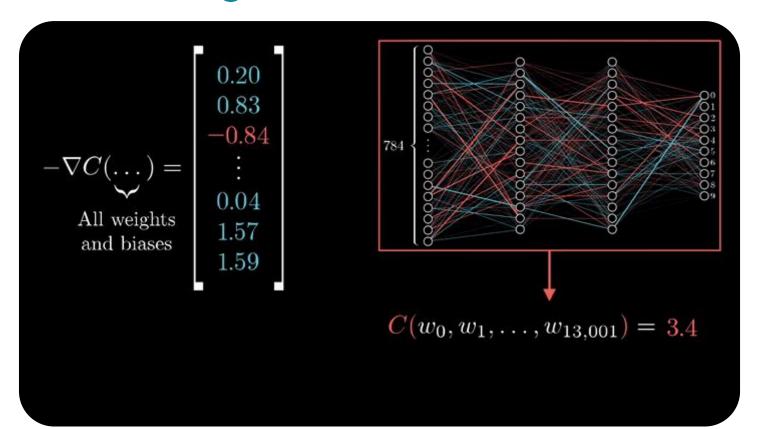




#### **GRADIENT DESCENT**

- "Método do gradiente" / "método do máximo declive"
- Procura mínimos locais na função
- Na prática nos diz como alterar os pesos e bias das conexões para diminuir o custo eficientemente

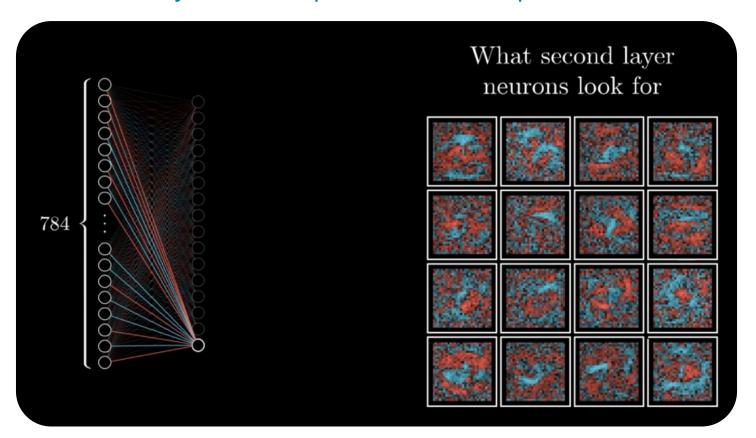
#### Backtracking



### Hidden layers na prática...



#### Hidden layers na prática... Alquimia.



### 6. Keras

Redes neurais artificiais na prática



#### 0 que é Keras?

- Biblioteca open source licenciada pelo MIT
- Cross-Platform: TensorFlow (que utilizaremos),
   Microsoft Cognitive Toolkit, Theano ou PlaidML
- Construção de redes neurais
- Escrita em Python

#### Por que utilizar Keras?

- Setup de modelos rápido
- User-friendly
- Experimentação
- Backend otimizado



# HANDS ON!

Bora criar nossa primeira rede neural artificial :))

# Inicialização

```
[3] import tensorflow as tf

model = tf.keras.models.Sequential()
```

## Adicionando camadas

```
[5] import tensorflow as tf

model = tf.keras.models.Sequential()

model.add(tf.keras.layers.Dense(16, activation=tf.nn.sigmoid, input_dim=784))

model.add(tf.keras.layers.Dense(16, activation=tf.nn.sigmoid))
model.add(tf.keras.layers.Dense(10, activation=tf.nn.sigmoid))
```

## .Flatten()

```
[14] import tensorflow as tf

model = tf.keras.models.Sequential()

model.add(tf.keras.layers.Flatten())

model.add(tf.keras.layers.Dense(16, activation=tf.nn.sigmoid, input_dim=784))
model.add(tf.keras.layers.Dense(16, activation=tf.nn.sigmoid))
model.add(tf.keras.layers.Dense(10, activation=tf.nn.sigmoid))
```

# Optimizer e loss

# Treino

```
[14] model.fit(x_train, y_train, epochs=5, batch_size=5)
```

## TL;DR

```
model = tf.keras.models.Sequential()
model.add(tf.keras.layers.Flatten())
model.add(tf.keras.layers.Dense(16, activation=tf.nn.sigmoid,
                                input dim=784))
model.add(tf.keras.layers.Dense(16, activation=tf.nn.sigmoid))
model.add(tf.keras.layers.Dense(10, activation=tf.nn.sigmoid))
opt = tf.keras.optimizers.SGD(lr=0.1)
model.compile(loss='mean squared error',
             metrics=['accuracy'], optimizer=opt)
model.fit(x train, y train, epochs=5, batch size=5)
```